



Ciberseguridad Inteligente: Machine Learning para detectar Phishing, Spam y Ataques de Ingeniería Social

Un taller sobre cómo la Inteligencia Artificial está cambiando el panorama de las ciberamenazas y las defensas.

Presentado por: ***M. en C. Joan David González Franco***

correo: joandavid@cicese.edu.mx

Agenda del Taller (Teoría + Práctica)

El Factor Humano

La ingeniería social y su efectividad persistente

Evolución de Amenazas

Desde correos spam básicos hasta deepfakes avanzados

Fundamentos IA, ML, DL

La base tecnológica de la ciberseguridad inteligente


Aplicaciones Prácticas

- Detección de Spam, Phishing e Ingeniería Social
- Análisis de anomalías en tráfico de red
- Identificación de vulnerabilidades web
- Creación de aplicaciones con IAs API (AI Gemini Studio)

Medición y Herramientas

- Métricas clave para evaluar modelos de ML
- Herramientas actuales y tendencias futuras
- El doble filo de la IA en ciberseguridad

Introducción a la Ciberseguridad Inteligente



La **Ciberseguridad Inteligente** es la aplicación de técnicas de Inteligencia Artificial (IA) y Machine Learning (ML) para proteger sistemas, redes y datos.

En lugar de depender únicamente de reglas y firmas estáticas, utilizamos modelos que pueden:

- **Aprender** de nuevos datos
- **Razonar** con los datos
- **Adaptarse** a amenazas desconocidas
- **Automatizar** la detección y respuesta a incidentes

El Doble Filo de la IA: Modelos Inseguros

Los modelos de IA, como los LLMs, se entrenaron para ser útiles, no seguros. Esto crea nuevas vulnerabilidades.


Es como un niño muy inteligente que sabe la respuesta a una pregunta peligrosa (ej: "¿cómo fabricar una bomba?"). Por defecto se le dice que no la diga, pero se le puede engañar para que lo haga.

Técnicas de ataque a la IA:

Jailbreaking & Prompt Injection: Engañar al modelo con prompts diseñados para saltarse sus restricciones de seguridad y obtener información o comportamientos no autorizados.



El lado oscuro en el uso de IA




Uso de IA para buscar vulnerabilidades

'Hacker' usó inteligencia artificial para identificar y extorsionar a empresas | Noticias Telemundo



Uso de DeepFake para estafar

Worker Sends \$25 Million To Deepfake CFO In WILD Fraud Case #TYT



Uso de DeepFakes para solicitudes de trabajo

Scammers using AI technology to dupe companies into hiring them

El Pilar de los Ciberataques: La Ingeniería Social

¿Qué es la Ingeniería Social?

Una técnica de manipulación psicológica utilizada para engañar a las personas y hacer que revelen información confidencial o realicen acciones que normalmente no harían.

Se aprovecha de debilidades humanas como la **confianza**, la **curiosidad** o el **miedo**, en lugar de vulnerabilidades técnicas.

El primer caso documentado podría ser el de Adán y Eva con la serpiente.

Es la técnica más eficaz para hacerse con secretos protegidos, ya que no requiere de una sólida información técnica, ni de grandes conocimientos sobre Sistemas Operativos, protocolos, etc.



El Ciclo de Vida de un Ataque de Ingeniería Social

Un ataque bien planeado sigue un proceso claro:



Investigar

Reunir información sobre la víctima para identificar sus debilidades, perfiles sociales, contactos y hábitos.



Enganchar (Hook)

Atrapar la atención de la víctima con falsas promesas o un pretexto creíble que genere confianza o urgencia.



Actuar

Manipular a la víctima para extraer la información confidencial o ejecutar el ciberataque planeado.



Salir

Finalizar la interacción y eliminar rastros o malware para cubrir las pistas de la intrusión.

Tipos Comunes de Ataques

La ingeniería social tiene muchas caras:



Phishing

Correos electrónicos falsos que suplantan a entidades legítimas para robar credenciales o instalar malware. Cada vez más sofisticados, imitan perfectamente comunicaciones oficiales.



Vishing

Suplantación de identidad mediante llamadas de voz. Los atacantes se hacen pasar por soporte técnico, bancos o incluso autoridades para obtener información sensible.



Baiting (Carnada)

Ofrecer algo atractivo (como una USB infectada) para que la víctima comprometa su seguridad al conectar el dispositivo a su sistema.



Pretexting

Crear un escenario o historia ficticia para ganarse la confianza de la víctima y obtener información confidencial mediante la suplantación de identidad.

Caso de Estudio: El Hackeo de Twitter en 2020

Un ejemplo perfecto de ingeniería social a gran escala que **afectó a más de 100 cuentas** de alto perfil como Elon Musk, Bill Gates, Bitcoin y Apple.

¿Cómo lo hicieron?

1. **Investigación:** Identificaron empleados clave de Twitter en LinkedIn.
2. **Ataque (Vishing/Phishing):** Llamaron a los empleados haciéndose pasar por el soporte técnico interno.
3. **Engaño:** Los dirigieron a una página de phishing que clonaba el portal VPN para robar credenciales y tokens 2FA.
4. **Acceso:** Con las credenciales robadas, accedieron a herramientas internas y tomaron control de cuentas de celebridades.




La Nueva Frontera: Ataques con Deepfake

La IA generativa ha llevado la ingeniería social a otro nivel. Los **deepfakes** son videos o audios manipulados que parecen increíblemente reales.

⊗ Caso Real

Un empleado de una multinacional fue engañado para transferir **25 millones de dólares** tras recibir una llamada de un deepfake que imitaba perfectamente la voz de su director financiero (CFO).



Las tecnologías de deepfake permiten crear videos y audios prácticamente indistinguibles de los originales.

¿Cómo Nos Defendemos? El Rol del Machine Learning



Si los atacantes usan tecnología avanzada, nosotros también debemos hacerlo. El **Machine Learning** es una de nuestras herramientas más poderosas para combatir estas amenazas a escala.

Evolución de la Defensa

1

Defensas Reactivas

Basadas en lo que ya conocemos (firmas, reglas estáticas)


2

Defensas Predictivas

Identificando amenazas nunca antes vistas mediante patrones aprendidos (Zero Days)

Conceptos de IA, ML, DL e IAGen

Para entender la ciberseguridad inteligente, es clave diferenciar sus pilares tecnológicos:



Cada capa se basa en la anterior, representando una progresión desde la automatización básica hasta la creación autónoma de contenido inteligente.

Fundamentos de ML para Ciberseguridad

¿Qué es el Machine Learning?

Es una rama de la IA que permite a los sistemas aprender de los datos sin ser programados explícitamente.



Modelos Clasificadores

Etiquetan datos en categorías predefinidas (ej: "spam" o "no spam"). Utilizan características aprendidas para determinar a qué clase pertenece cada elemento nuevo.



Detección de Anomalías

Identifican patrones inusuales que se desvían del comportamiento normal. Cruciales para detectar ataques zero-day o comportamientos sospechosos no vistos antes.



Entrenamiento

El proceso de "enseñar" a un modelo usando un conjunto de datos. Se necesitan datos de calidad y en cantidad suficiente para crear modelos robustos y precisos.

Evaluación de Modelos de Seguridad

Un modelo con "99% de precisión" puede ser terrible. Necesitamos las métricas correctas.

Precisión (Precision)

De todas las alertas que generó, ¿cuántas fueron realmente amenazas? Ayuda a evitar los falsos positivos que generan fatiga de alertas.

Exhaustividad (Recall)

De todas las amenazas reales, ¿cuántas logró detectar el modelo? Crucial para evitar que amenazas pasen desapercibidas.

❌ Falso Positivo

Una alerta sobre una amenaza que no existía. Genera trabajo innecesario y puede llevar a que se ignoren alertas reales.

⚠️ Falso Negativo

No detectar una amenaza real. **¡Este es el más peligroso!**
Puede permitir que un ataque continúe sin ser detectado.

En ciberseguridad, a menudo preferimos tener algunos falsos positivos a tener un solo falso negativo crítico.

Herramientas Prácticas de Reconocimiento

La primera fase de un ataque es la investigación. Podemos usar las mismas herramientas para evaluar nuestra propia exposición.



Google Hacking (Dorks)

Búsquedas avanzadas para encontrar información sensible expuesta públicamente.

```
ext:sql inurl:gob.mx
```

Este ejemplo buscaría archivos SQL expuestos en sitios gubernamentales mexicanos.



Have I Been Pwned

Verifica si tus credenciales han sido expuestas en alguna brecha de datos. Esencial para comprobar si las contraseñas corporativas están comprometidas.



Shodan

El "Google de los dispositivos conectados". Permite encontrar desde servidores hasta cámaras web mal configuradas pertenecientes a tu organización.

Aplicación 1: Detección de Spam y Phishing



¿Cómo funciona?

Un modelo de ML analiza miles de correos electrónicos y aprende a distinguir las características de un mensaje malicioso.

Características (Features) que analiza:

- El remitente y la reputación del dominio
- La presencia de palabras clave sospechosas ("urgente", "premio", "verificar cuenta")
- La estructura de las URLs y si usan acortadores
- El formato y la gramática del texto

El modelo asigna una probabilidad de que el correo sea phishing o spam y lo bloquea si supera un umbral determinado.

Desarrollo de un Modelo Clasificador

El proceso para crear un detector de phishing sigue estos pasos:

01

Recopilación de Datos

Juntar un gran dataset de correos electrónicos ya etiquetados como phishing o legítimos. La calidad y cantidad de estos datos determinarán en gran medida la eficacia del modelo.

03

Entrenamiento del Modelo

Alimentar los datos a un algoritmo de clasificación (ej: Regresión Logística, Random Forest, Redes Neuronales). Ajustar hiperparámetros para optimizar el rendimiento.

02

Ingeniería de Características

Extraer los atributos relevantes de cada correo (remitente, asunto, enlaces, contenido HTML, metadatos). Transformar datos no estructurados en características medibles.

04

Evaluación

Medir qué tan bueno es el modelo para identificar nuevos correos maliciosos utilizando métricas como precisión, exhaustividad y tasa de falsos positivos.

Aplicación 2: Detección de Anomalías en Tráfico de Red

¿Cómo funciona?

Línea Base (Baseline)


El modelo aprende cómo se ve el tráfico "normal" de la red (qué dispositivos se conectan, a qué horas, qué volumen de datos transfieren).

Monitorización Continua

El sistema vigila el tráfico en tiempo real, comparándolo con los patrones aprendidos durante la fase de entrenamiento.

Detección y Alerta

Se generan alertas sobre cualquier actividad que se desvíe significativamente de la línea base establecida como normal.



⚠ **Ejemplo de anomalía:** Un empleado que de repente empieza a subir gigabytes de datos a un servidor desconocido a las 3 AM sería rápidamente detectado.

Aplicación 3: Identificar Vulnerabilidades con Web Scraping




Podemos usar técnicas de web scraping de forma **defensiva**.

¿Cómo funciona?

Un script automatizado puede "raspar" o analizar los formularios de nuestras propias aplicaciones web para buscar vulnerabilidades comunes:

- **Falta de validación de entradas:** ¿Permite el formulario inyectar código malicioso (XSS, SQL Injection)?
- **Endpoints expuestos:** ¿Hay APIs o páginas que no deberían ser públicas?
- **Contraseñas por defecto:** ¿Los paneles de administración son accesibles con credenciales conocidas?

Aplicación 4: Defensas con IA Moderna



Podemos usar herramientas de IA modernas para construir nuestras propias soluciones de seguridad.

Google AI Studio (Gemini)

Potentes modelos de lenguaje generativo accesibles vía API que pueden analizar textos sospechosos y detectar intentos de ingeniería social.

LangChain

Un framework que facilita la conexión de estos modelos con fuentes de datos externas para crear aplicaciones complejas de ciberseguridad.

Con ellos, podemos crear chatbots para analizar correos sospechosos, generar reportes de seguridad o incluso automatizar respuestas a incidentes en tiempo real.

Conclusiones y Cómo Protegerse



La Ingeniería Social es la mayor amenaza

Explota al eslabón más débil: el ser humano. El 80% de los ataques están relacionados con errores humanos.



La IA es un arma de doble filo

Está potenciando tanto los ataques como las defensas. Debemos entender ambas caras de la moneda.



La mejor defensa es el conocimiento

La conciencia y educación sobre estas tácticas son nuestra primera línea de defensa.

Recomendaciones Prácticas:

Sé escéptico

No confíes en comunicaciones no solicitadas, especialmente si generan urgencia o piden acciones inmediatas.

Verifica siempre

Llama a un número conocido para confirmar una solicitud inusual, incluso si parece venir de un superior.

Educa y entrena

Implementa programas regulares de formación en ciberseguridad para toda la organización.

Preguntas y Agradecimientos

¿Preguntas?

M. en C. Joan David González Franco

correo: joandavid@cicese.edu.mx

LinkedIn: <https://www.linkedin.com/in/joandgonzalezf/>

Gracias por su atención.

No dudes en contactar para más información sobre cómo implementar soluciones de ciberseguridad inteligente en tu organización.

